

# 리튬 이온 배터리 팩 내에서 열화 셀 검출을 위한 SOH(State of Health) 딥러닝 알고리즘에 관한 연구

정대원, 정인엽, 조운, 김윤선, 김인균, \*전준현

동국대학교 전자전기공학과

e-mail : jung1362@dgu.edu, vision@dgu.ac.kr, chowoon177@dgu.edu, fine@dgu.edu, deep@dgu.ac.kr, memory@dgu.edu

## A Study on a SOH Deep Learning Algorithm for Degradation Cell Detection in Lithium-ion Battery Pack

Daewon Chung, Inyeob Jeong, Woon Cho, Yunsun Kim, Ingyun Kim,

\*Joonhyeon Jeon

Division of Electronics & Electrical Engineering Dongguk University

### I. 서론

#### Abstract

리튬 이온 배터리(Lithium Ion Battery, LIB) 팩의 안정적 장기 운용을 위해서는 열화 셀들의 검출을 위한 정확한 SOH (State of Health) 추정이 필수적이다. 본 논문에서는 SOH 추정의 정확도를 높이기 위해, LIB팩 및 각 셀들의 시계열 데이터들을 파라미터화한 RNN(Recurrent Neural Network) 구조의 LSTM(Long Term Short Memory) 알고리즘을 제안하였다. 제안된 방식의 우수성을 증명하기 위해 13개 셀을 직렬 연결한 배터리 팩 20개를 사용, 1,000 cycle 충방전, 온도, 습도 데이터들을 학습에 사용하였다. 실험결과 제안된 네트워크 구조를 갖는 LSTM은 기존 LSTM과 비교하였을 때 11.2%의 정확도 향상을 나타내었다. 이와 함께, 학습된 모델을 통하여 추출된 가변적 셀-열화 임계값(cell degradation threshold)은 손상된 셀들을 정확하게 검출함을 확인할 수가 있었다. 본 연구는 종래 SOH 알고리즘들이 가지는 문제점을 해결하고 보다 최적화된 시스템을 제공함을 보여준다.

오늘날 산업 전반에 걸쳐 가장 많이 사용되고 있는 2차전지 중 하나로 리튬이온전지(이하, LIB)를 꼽을 수 있다. 기전력이 3.6V이며, 매우 가벼운 특성으로 타 전지보다 무게 대비 높은 에너지 밀도와 자가방전에 의한 전력손실이 매우 적다는 탁월한 장점을 지녀 스마트폰 등 소형 모바일 기기에서 전기자동차까지 전력원으로 쓰이고 있다. 최근 신차 판매의 25%가 전기 엔진을 탑재한 차량들이며, 환경 오염이나 기후 변화에 대한 대응으로 전기자동차 운용이 적극 장려되는 등 수요가 급증하고 있다. 그러나 가장 널리 알려진 단점으로 온도에 민감한 특성으로 인해 온도가 높은 환경일수록 노화가 빨리 진행됨과 동시에 폭발 위험성도 증가한다. 이에 전기자동차에 쓰이는 LIB 팩은 다양하고 혹독한 환경에서 안정적으로 동작하여야 하고, 정밀하게 관리되어야 한다. 이를 위해 최근에는 열적 불안전성 원인 규명을 포함 리튬 전지의 안정성을 위협하는 내·외부적 요인들에 대한 연구가 활발히 진행되고 있다. 일반적으로 전지의 열화상태를 수치적으로 제시하는 SOH를 모델링하여 현재 전지의 상태를 파악하는데, 기존의 방법으로는 내부 저항 / 임피던스[1], 충전용량, 누적 충방전 사이클 수 등을 이용하여 대략적인 SOH를 산출하거나 칼만필터[2],

퍼지 로직, 또는 연속되는 사이클 간의 SOC 변화량을 이용하여 SOH를 추정하는 기법 등이 있다. 그러나 이런 기법들은 SOH 추정에 이용되는 파라미터가 제한적이며, LIB 전체 성능 저하와 폭발을 유발하는 다양한 요인들에 대한 고려가 되지 않아 장기 사이클 및 다양한 환경에서 운용 시 결국 추정 및 예측 정확도가 떨어진다는 치명적인 단점을 지닌다. 이러한 문제를 해결하기 위해 본 논문에서는 다양한 파라미터를 고려하여 학습하는 딥러닝 네트워크 구조와 이를 기반으로 열화 판단 임계값을 산출하여 열화 셀을 검출해 낼 수 있는 시스템을 제안한다.

## II. 본론

### 2.1 학습 및 예측부

본 논문에서 제안하는 시스템은 그림 1과 같이 크게 학습 및 예측부와 검출부 2가지로 나눌 수 있고, 본 절에서는 전자에 대해 서술한다.

먼저 13개 셀을 직렬 연결한 LIB 팩 20개의 1000cycle 충방전, 온도, 습도 데이터를 이용, RNN 계열 중 시계열 데이터 학습에 강력한 성능을 보이는 LSTM을 이용하여 딥러닝 네트워크를 학습시킨다[3, 4]. 이 때, 전압, capacity, 온도와 같은 경우는 LIB 팩 전체의 데이터 값과, 해당 LIB 팩 내의 셀 별 데이터 값을 동일 모델 내에서 병렬 학습시킨다. 이를 통해 팩 단위의 운용에서는 정상 범주에 있더라도 그 내부에서의 이상동작을 하는 셀을 검출해 낼 수 있는 정보를 얻을 수 있다. 또한 팩 내부의 셀의 위치까지 고려하여 파라미터화하고 학습시킴으로써 가운데 배치된 셀보다 양 끝단에 배치된 셀이 상대적으로 더 열화 된다는 실험적 정보까지 반영하여 보다 정확한 SOH를 제공하는 모델 설계가 가능하다. 습도의 경우 팩 전체의 습도와 팩 내부 셀 별 습도의 변화 양상이 거의 동일하기에 연산량을 줄이기 위하여 단일

파라미터로 학습시킨다. 상기 4가지 카테고리의 딥러닝 모델을 통해 동시에 학습되는 가중치들은 아래와 같은 그림 1에 포함된 수식으로 최적화된다.

추가적으로 기준사이클(3<sup>rd</sup> cycle)을 시작으로 각 사이클마다의 유효충전시작지점, 충전 피크지점, 유효방전종료지점을 잇는 충전전압/방전전압 기울기를 계산하여 독립된 딥러닝 모델로 학습, 최종 산출되는 SOH값을 보정하여 정확도를 극대화 시킬 수 있다. 이와 같은 방법으로 설계된 데이터 예측부는 종래에 사용되던 기법보다 정확한 SOH를 제공할 수 있다.

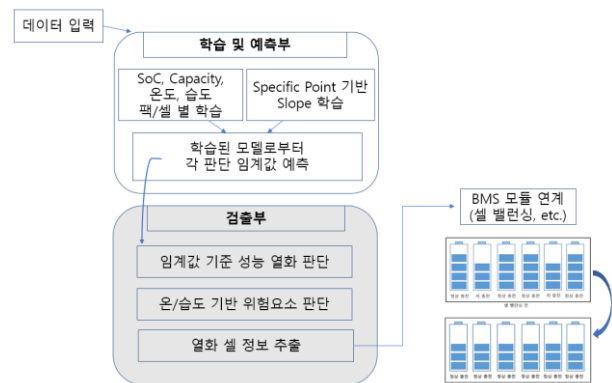


그림 2. 제안된 시스템의 기본 구조

### 2.2 검출부

다음 검출부에서는 임의의 이상동작을 하는 셀이 존재하는지 확인하려는 대상 LIB 팩의 현재 사이클 데이터를 입력으로 받는다. 이때 입력은 온전한 하나의 사이클이어야 하며, 현재 사이클(n번째)의 충방전이 진행중이라면 입력데이터는 n-1번째 사이클의 전체 데이터를 이용한다. 입력 받은 데이터를 기반으로 팩 전체의 SoC와 Capacity를 계산하고, 학습 및 예측부로부터 해당사이클의 예측값을 얻어 두 값의 Mean Squared Error(이하, MSE)값을 구해 팩 내부의 셀 별 확인을 시작할지 판단한다. 이때 구한 MSE값이 E(K, q) 값(이 기준은 LIB 팩 내 셀의 개수와, 운용환경에 따라 달리할 수 있으며 최적화가 가능하다.)을 넘어서면 팩 내부에 임의의 이상동작을 하는 셀이 존재하는 것으로 판단하여 팩 내부 전체 셀에 대하여 SoC와 Capacity 값 계산 및 예측값과의 MSE 산출 및 대소비교를 통해 이상 여부를 확인한다. 이때 한 개 이상의 셀의 SoC와 Capacity가 정상 범주 밖에 있는 것이 확인되면, 다음으로 팩 내부 전체 셀에 대하여 기준사이클(세번째 사이클) 대비 현재 사이클의 평균 온도 및 습도 변화량을 계산한다. 전체 셀에 대하여 계산된 두 값 모두 각각 학습 및 예측부로부터 얻어낸 예측 임계값  $\epsilon_{T,i}$ ,  $\epsilon_{H,i}$  보다 작다면(시스템 내에서는

$$V_t = \sigma(W_V * X + B_V) : \text{전압(V) 변화를 학습한 모델에서의 산출 가중치}$$

$$C_t = \sigma(W_C * X + B_C) : \text{Capacity(C) 변화를 학습한 모델에서의 산출 가중치}$$

$$T_t = \sigma(W_T * X + B_T) : \text{온도(T) 변화를 학습한 모델에서의 산출 가중치}$$

$$H_t = \sigma(W_H * X + B_H) : \text{습도(H) 변화를 학습한 모델에서의 산출 가중치}$$

$$P_t = \text{ReLU}(V_t * h_{(t-1)} + C_t * h_{(t-1)}) \quad (\text{전기화학적 요소})$$

$$Q_t = \text{ReLU}(T_t * h_{(t-1)} + H_t * h_{(t-1)}) \quad (\text{외부환경 요소})$$

$$\text{최종 출력 } h(t) = KP_t * h_{(t-1)} + (1-K)Q_t * h_{(t-1)} \quad (0 < K < 1)$$

( \* 기호는 컨볼루션 연산, K는 LIB 팩 운용 환경을 고려한 Weighting Factor,  $\sigma$ 는 시그모이드 활성화 함수, ReLU는 활성화 함수, W는 가중치, X는 입력, B는 바이어스 값)

그림 1. 제안된 학습 네트워크의 가중치 취합 구조

논리곱연산으로 이를 검출함.), 정상적으로 운용되지만 특정 셀의 전기화학적 성능이 떨어져 있는 상태이므로 이후 추가 배터리관리시스템(이하, BMS)의 셀 밸런싱 모듈 등과 연계하여 안정적인 운용 단계로 조치할 수 있다. 그러나 예측 임계값을 넘어서는 셀이 있다면 이는 전기화학적 성능과 외부 환경에 모두 문제가 있음을 의미하므로, 해당 셀을 교체하는 등 능동적인 조치를 통해 보다 안정적인 시스템 운용이 가능하다.

### III. 실험 결과

13개 셀을 직렬 연결한 LIB 팩 20개의 1000 cycle 충방전, 온도, 습도 데이터를 이용하여 LSTM 알고리즘을 토대로 네트워크를 학습시키고, 이를 기반으로 SOH를 추정하였다. 그림 3에서 기존의 단순 수식을 통해 산출한 SOH 값을 LSTM으로 학습 및 예측한 방법과 본 논문에서 제안하는 강화된 딥러닝 네트워크 기반의 방법을 비교하였다. 비교 결과 제안된 딥러닝 모델의 error율이 기존 대비 11.2% 감소되었다.

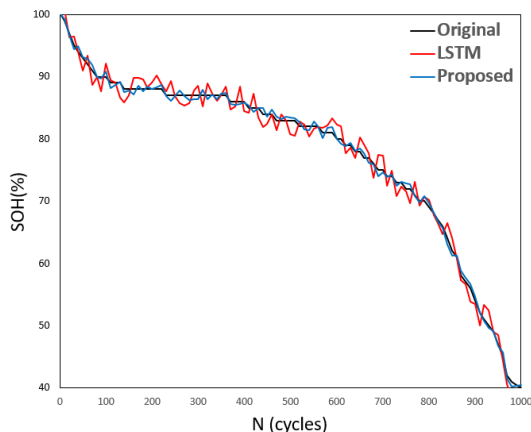


그림 3. 기존 방식과 제안된 방식 비교

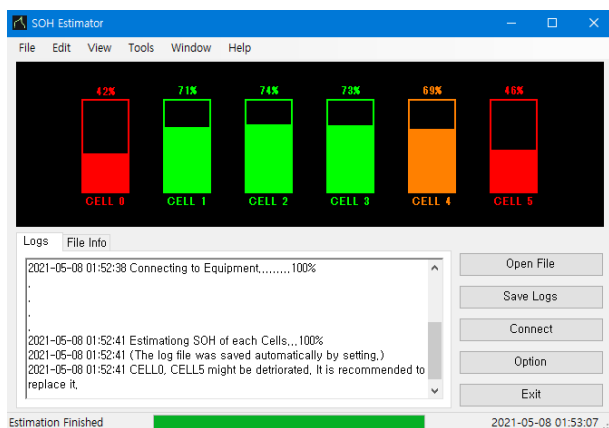


그림 4. 구현된 제안 시스템의 구동 예

그림 4는 본 논문에서 제안하는 시스템을 기반으로 열화 판단 임계값을 통해 열화된 셀을 검출해내는 실제 예시를 보여준다.

### IV. 결론 및 향후 연구 방향

본 연구를 통해 종래에 사용되던 SOH 추정 기법보다 향상된 정확도를 지닌 모델을 제시하고, 나아가 예측된 판단 임계 값을 통해 임의의 이상동작을 하는 셀을 검출해냄으로써, LIB 팩의 안정적으로 운용될 수 있도록 하는 방법 및 그 장치를 제공할 수 있다. 또한 추가 배터리관리시스템(이하, BMS)의 셀 밸런싱 모듈 등과 연계하여 안정적인 운용을 제공할 수 있다.

#### 감사의 글

본 연구는 2021년도 정부의 재원으로 한국 에너지기술연구원(산업통상자원부) 연구비 지원과 중소벤처기업부의 기술개발사업 지원에 의한 연구임 (20194030202320, 레독스흐름전지(RFB)의 핵심 부품·소재 고급트랙), (S2849798, SOH기법을 이용한 5G기지국 비상전원의 리튬이온 배터리 BMS개발)

#### 참고문헌

- [1] 노동윤 외, “리튬폴리머 배터리의 OCV를 이용한 배터리 SOH 추정 방법”, 전력전자학회 학술대회 논문집, pp. 269–270, 2010.
- [2] 고영휘 외, “단일 확장 칼만 필터를 이용한 리튬 배터리의 SOC 및 SOH 추정법”, 전력전자학회 추계 학술대회 논문집, pp.79–81, 2019
- [3] K. Kirandeep, et al. “Deep learning networks for capacity estimation for monitoring SOH of Li-ion batteries for electric vehicles.”, International Journal of Energy Research, Vol. 45, pp.3113–3128, 2021
- [4] Y. Tan, et al. “Transfer Learning With Long Short-Term Memory Network for State-of-Health Prediction of Lithium-Ion Batteries”, IEEE Transactions on Industrial Electronics, Vol. 65, pp.8721–8731, 2019